Analisis Kompresi Margin: Evaluasi Efektivitas Program Loyalitas Terhadap Profitabilitas Ritel

Bootcamp Final Project • Python • Power BI • Raden Maulana Akbar • November 2026

Table of Content

- INTRODUCTION
  - PROJECT OVERVIEW
    - PROBLEM STATEMENT
      - DATA UNDERSTANDING
        - DATA EXPLORATION
          - DATA CLEANING
            - EXPLORATORY DATA ANALYSIS
              - DASHBOARD
                - DATA ANALYSIS
                  - HASIL ANALISA
                    - REKOMENDASI BISNIS

INTRODUCTION

Self-Overview

Raden Maulana Akbar



Seorang *Data Analyst* student *intensive bootcamp* di **dibimbing.id** yang memiliki motivasi tinggi dalam memecahkan masalah bisnis dan mengoptimalkan performa penjualan. Mahir melakukan *data cleaning* serta membangun *dashboard* interaktif menggunakan Excel, Python, PostgreSQL, dan Power BI. Berpengalaman dalam menganalisis data keranjang belanja (*market basket data*) untuk mengidentifikasi pola pembelian konsumen dan merumuskan rekomendasi strategis yang aplikatif. Antusias untuk mendorong pengambilan keputusan berbasis data (*data-driven decision-making*).

Education

- SMAN 7 Bekasi

LinkedIn

GitHub

Project Overview

1. Analisis Kegagalan Layanan Digital & Kabin Maskapai

Deskripsi: Analisis kepuasan pelanggan penerbangan (CSAT) menggunakan PostgreSQL & Power BI.
Tujuan: Menginvestigasi pemicu utama ketidakpuasan dan mencegah customer churn.
Hasil: CSAT tertahan di 43,34%. Akar masalah bukan delay, melainkan buruknya Online boarding & Inflight entertainment, di mana 76,64% penumpang tidak puas adalah Loyal Customer.

2. Analisis Efisiensi Periklanan & Retensi Pelanggan

Deskripsi: Evaluasi efektivitas anggaran iklan berbayar (paid ads) dan retensi pengguna situs.
Tujuan: Menganalisis apakah perolehan trafik memberikan pertumbuhan sehat atau profit leakage.
Hasil: Paid Ads tidak efisien (ROAS 1.20x), sementara kanal organik menyumbang pendapatan terbesar tanpa biaya. Kebocoran trafik terbesar terjadi pada transisi landing page ke keranjang.

3. Profitability & Discount Impact Analysis

Deskripsi: Analisis dampak diskon terhadap margin keuntungan ritel menggunakan Excel & Power BI.
Tujuan: Mengukur apakah diskon mendongkrak laba atau memicu pendarahan finansial.
Hasil: Diskon di atas 20% terbukti menjadi akar kerugian bersih (terutama produk berat seperti Machines dan Tables di wilayah South dan East).

4. Employee Attrition & High-Performance Loss Analysis

Deskripsi: Analisis sumber daya manusia (HR Analytics) untuk membedah pola resign karyawan di Excel.
Tujuan: Menganalisis tingkat attrition rate makro dan risiko kehilangan talenta unggul.
Hasil: Overall attrition sangat tinggi di angka 51,1%. Sebanyak 356 di antaranya adalah High Performer (23,2%), terkonsentrasi di departemen Production dan Sales.

5. Analisis Jenis Produk & Visibilitas Rak Ritel (BigMart Sales)

Deskripsi: Data preprocessing & eksplorasi Python untuk menganalisis pengaruh visibilitas rak terhadap omzet.
Tujuan: Mengoptimalkan tata letak rak toko agar penjualan lebih efisien.
Hasil: Fruits and Vegetables mendominasi omzet total, sementara Starchy Foods mencatatkan rata-rata penjualan per produk tertinggi. Visibilitas rak yang luas tidak menjamin tingginya penjualan tanpa permintaan pasar.

6. Analisis Biaya Pengiriman E-Commerce (Olist Logistics)

Deskripsi: Analisis logistik menggunakan PostgreSQL untuk menekan pembengkakan ongkir di wilayah terpencil.
Tujuan: Mengisolasi penyebab ongkir mahal dan merumuskan efisiensi logistik.
Hasil: Masalah ongkir mahal bersifat terisolasi (~10% transaksi, terparah di Rondônia). Analisis membuktikan ongkir mahal dipicu oleh jarak distribusi, bukan berat barang.

Problem Statement

Market Basket Analysis: Menggali Pola Pembelian Konsumen untuk Meningkatkan Penjualan Ritel

Evaluasi dari Forbes Business Development Council menegaskan bahwa keberhasilan program loyalitas ritel sangat bergantung pada kalibrasi insentif yang presisi agar tidak mengorbankan margin keuntungan perusahaan. Banyak bisnis terjebak dalam pemberian potongan harga yang terlalu agresif, yang secara tidak disadari menekan harga jual hingga terlalu rapat dengan harga modal dasar. Akibatnya, alih-alih menjadi pendorong pertumbuhan yang sehat, skema insentif tersebut justru memicu kompresi margin dan menggerus profitabilitas operasional. Berkaca dari risiko "jebakan diskon" tersebut, evaluasi strategis ini diinisiasi untuk mendiagnosis efektivitas struktur insentif membership serta merumuskan kembali strategi harga demi mengembalikan kesehatan margin tanpa mengorbankan retensi pelanggan.

Data Understanding

Sumber Data : Indian FMCG Retail Sales Customer Inventory (2024).csv

Dataset ini berisi catatan transaksi ritel FMCG tingkat faktur (invoice-level) sepanjang tahun 2024 yang mencakup 100.000 transaksi di 8 kota metropolitan utama di India. Data ini merekam atribut kunci operasional dan finansial—termasuk status keanggotaan pelanggan (Member vs Non-Member), saluran penjualan (Online, Offline, Omnichannel), persebaran kategori produk, serta struktur harga modal (Cost Price) dan harga jual (Selling Price). Seluruh variabel ini difokuskan untuk mendiagnosis dinamika profitabilitas, mengidentifikasi transaksi Underperforming, serta mendeteksi potensi kompresi margin akibat efektivitas program loyalitas perusahaan.

Link Github untuk project ini: klik disini

Data Understanding

Sumber Data : Indian FMCG Retail Sales Customer Inventory (2024).csv

Invoice_ID	Invoice_Date	City	Store_Format	Category	Brand	Channel	Payment_Mode	Units	Cost_Price	Selling_Price	Revenue	Cost	
58018430	2024-02-02 13:50:00	Kolkata	Super	Grocery	Nestle	Online	Wallet	2	148.999035	175.057209	350.114418	297.998070	
48157952	2024-10-09 11:52:00	Hyderabad	Hyper	Home Care	PepsiCo	Offline	Wallet	1	80.626759	106.034197	106.034197	80.626759	
23283831	2024-08-26 22:03:00	Chennai	Hyper	Snacks	PepsiCo	Online	Card	5	181.233170	208.980023	1044.900114	906.165848	1
53537460	2024-06-09 04:34:00	Bengaluru	Hyper	Beverages	Nestle	Omnichannel	Card	2	195.811402	260.879960	521.759920	391.622805	1

Margin	Margin_%	Stock_On_Hand	Reorder_Level	Lead_Time_Days	Customer_Age	Customer_Gender	Loyalty_Flag
52.116348	0.148855	154	31	11	20.0	M	1
25.407438	0.239616	130	24	5	26.0	F	1
138.734266	0.132773	270	44	8	27.0	F	0
130.137115	0.249420	403	63	8	NaN	F	0

Deskripsi kolom Dataset

Nama kolom	Deskripsi
Invoice_ID	Pengidentifikasi unik untuk setiap transaksi ritel
Invoice_Date	Tanggal terjadinya transaksi
City Metro	Kota tempat penjualan terjadi
Store_Format	Jenis gerai ritel seperti Super, Hyper, Express
Category	Kategori produk FMCG
Brand	Nama merek dari produk yang dijual
Channel	Saluran penjualan tempat pembelian dilakukan
Payment_Mode	Metode pembayaran seperti Uang Tunai, Kartu, atau UPI
Units	Jumlah unit yang terjual dalam transaksi
Cost_Price	Harga modal per unit dalam INR (Rupee India)
Selling_Price	Harga jual per unit dalam INR (Rupee India)
Revenue	Total pendapatan yang dihasilkan dari transaksi

Nama kolom	Deskripsi
Cost	Total biaya yang dikeluarkan untuk unit yang terjual
Margin	Keuntungan absolut yang diperoleh dari transaksi
Margin_%	Margin keuntungan yang dinyatakan dalam bentuk persentase
Stock_On_Hand	Persediaan barang yang tersedia pada saat penjualan
Reorder_Level	Ambang batas stok yang memicu pengisian ulang pasokan
Lead_Time_Days	Waktu tunggu dari pemasok dalam hitungan hari
Customer_Age	Usia pelanggan
Customer_Gender	Jenis kelamin pelanggan
Loyalty_Flag	Menandakan apakah pelanggan terdaftar dalam program loyalitas

Feature Engineering

Nama Feature	Deskripsi
Margin_Leakage_Flag	Penanda status transaksi: Underperforming (< rata-rata margin 19,34%) dan Overperforming (≥ rata-rata).
Revenue at Risk	Measure DAX yang menjumlahkan total pendapatan dari seluruh transaksi berstatus Underperforming.
Transaction ID	Kolom penanda unik yang mewakili setiap transaksi
Age Group	Kolom untuk penanganan nilai hilang pada kolom umur kustomer
Customer Type	Kolom hasil transformasi Loyalty Flag menjadi kategori Member dan Non-Member.

Data Exploration

Cek Info kolom

```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 100000 entries, 0 to 99999
Data columns (total 21 columns):
 #   Column           Non-Null Count   Dtype
---  ------           --------------   -----
 0   Invoice_ID       100000 non-null  int64
 1   Invoice_Date     100000 non-null  str
 2   City             100000 non-null  str
 3   Store_Format     100000 non-null  str
 4   Category         100000 non-null  str
 5   Brand            100000 non-null  str
 6   Channel          100000 non-null  str
 7   Payment_Mode     100000 non-null  str
 8   Units            100000 non-null  int64
 9   Cost_Price       100000 non-null  float64
 10  Selling_Price    100000 non-null  float64
 11  Revenue          100000 non-null  float64
 12  Cost             100000 non-null  float64
 13  Margin           100000 non-null  float64
 14  Margin_%         100000 non-null  float64
 15  Stock_On_Hand    100000 non-null  int64
 16  Reorder_Level    100000 non-null  int64
 17  Lead_Time_Days   100000 non-null  int64
 18  Customer_Age     59919 non-null   float64
 19  Customer_Gender  94952 non-null   str
 20  Loyalty_Flag     100000 non-null  int64
```

Hasil Pengamatan

Berdasarkan output df.info(), dataset ini memuat **100.000 baris transaksi** dan **21 kolom**, namun terdapat **missing values** pada kolom **Customer_Age** dan **Customer_Gender**. Selain itu, diperlukan penyesuaian tipe data, seperti **Invoice_Date** ke **datetime**, **Invoice_ID** ke **string**, **Loyalty_Flag** ke **boolean**, serta konversi 7 kolom kategorikal ke category demi efisiensi memori RAM yaitu **kolom City, Store_Format, Category, Brand, Channel, Payment_Mode, dan Customer_Gender**. Selanjutnya akan memeriksa kelengkapan data dan juga pemeriksaan lanjut pada missing values pada kolom Customer_Age dan Customer_Gender.

Data Exploration

Cek Kelengkapan Data

Indikator Pemeriksaan	Jumlah Pemeriksaan	Persentase
Jumlah Duplikasi	0	0.00%
Jumlah Missing Values	45,129	45.13%

Cek Kelengkapan Data

	Jumlah_Missing	Persentase (%)
Customer_Age	40081	40.08
Customer_Gender	5048	5.05

Export Dataframe Berisi Nilai Unik

```
# Export dataframe untuk dianalisa oleh AI nilai yang tidak konsisten
df_cekdf.to_csv('cek_konsisten_finpro.csv', index=False)
```

Cek Konsistensi Data

	Nama_Kolom	nilai_Unik	Jumlah_Unik
0	Invoice_ID	[58018430, 48157952, 23283831, 53537460, 55348...	99938
1	Invoice_Date	[2024-02-02 13:50:00, 2024-10-09 11:52:00, 202...	91057
2	City	[Kolkata, Hyderabad, Chennai, Bengaluru, Delhi...	8
3	Store_Format	[Super, Hyper, Express]	3
4	Category	[Grocery, Home Care, Snacks, Beverages, Dairy,...	8
5	Brand	[Nestle, PepsiCo, ITC, Tata, Britannia, Amul, ...	8
6	Channel	[Online, Offline, Omnichannel]	3
7	Payment_Mode	[Wallet, Card, Cash, UPI]	4
8	Units	[2, 1, 5, 3, 4]	5
9	Cost_Price	[148.9990350915146, 80.62675927847314, 181.233...	100000
10	Selling_Price	[175.05720921867808, 106.03419727023002, 208.9...	100000
11	Revenue	[350.11441843735616, 106.03419727023002, 1044....	100000
12	Cost	[297.9980701830292, 80.62675927847314, 906.165...	100000
13	Margin	[52.116348254326965, 25.40743799175688, 138.73...	100000
14	Margin_%	[0.1488551899317217, 0.2396155075046739, 0.132...	100000
15	Stock_On_Hand	[154, 130, 270, 403, 366, 443, 108, 231, 124, ...	450
16	Reorder_Level	[31, 24, 44, 63, 40, 56, 66, 47, 23, 48, 59, 6...	60
17	Lead_Time_Days	[11, 5, 8, 9, 6, 13, 10, 3, 12, 4, 14, 7]	12
18	Customer_Age	[20.0, 26.0, 27.0, 60.0, 41.0, 61.0, 63.0, 46....	47
19	Customer_Gender	[M, F, O]	3
20	Loyalty_Flag	[1, 0]	2

Hasil Pengamatan

ditemukan **missing values** pada kolom **Customer_Age** sebesar **40,08% (40.081 baris)** dan **Customer_Gender sebesar 5,05% (5.048 baris)**, serta indikasi **duplikasi transaksi** karena **Invoice_ID** hanya memiliki **99.938 nilai unik**. Sebagai langkah penanganan data, nilai kosong pada **Customer_Gender** diimputasi menjadi **'O' (Other)**, **Customer_Age** dikelompokkan ke dalam kategori rentang usia baru dengan label **'Unknown'** untuk data kosong, serta dilakukan penelusuran lebih lanjut terhadap **duplikasi Invoice_ID** sebelum tahap analisis dilakukan.

Data Exploration

Cek duplikasi kolom Invoice_Date

Keterangan	Nilai	Persentase Duplikasi
Jumlah ID Unik yang Duplikat	62	0.06%

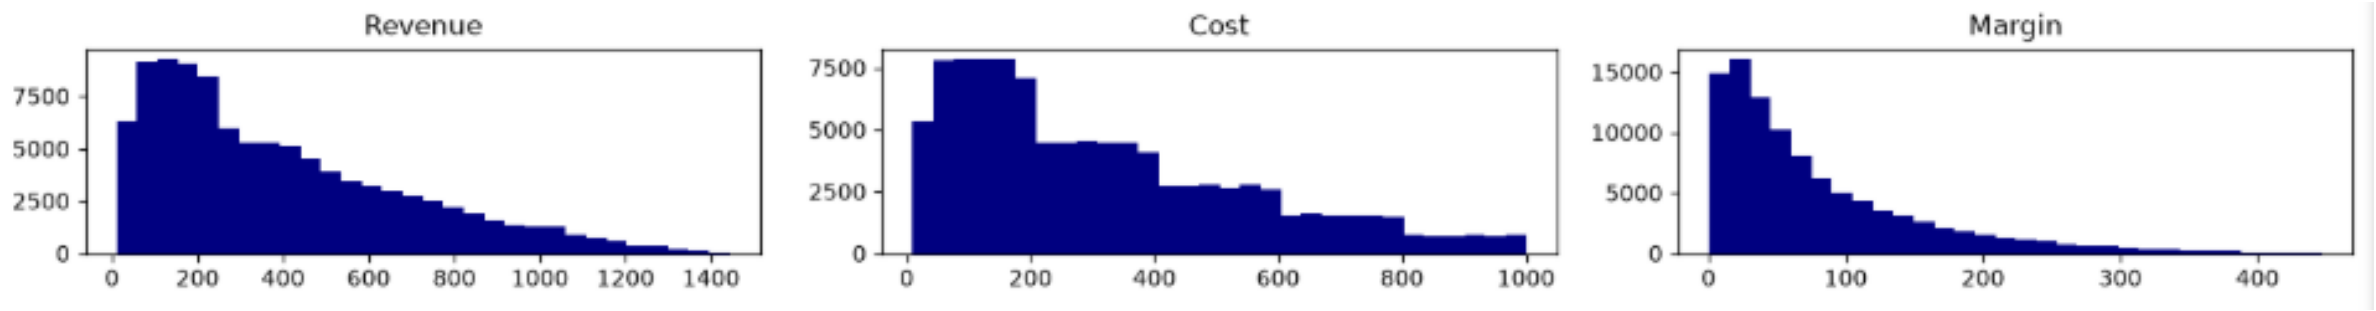
Invoice_ID	Invoice_Date	City	Store_Format	Category	Brand	Channel	Payment_Mode	Units	Cost_Price
10626453	2024-05-08 17:34:00	Ahmedabad	Super	Dairy	Nestle	Omnichannel	Wallet	3	127.292978
10626453	2024-05-24 08:36:00	Hyderabad	Super	Personal Care	Parle	Omnichannel	Card	1	194.537132

Hasil Pengamatan

Ditemukan **62** Invoice_ID **terulang (0,06%)** dengan rincian transaksi yang sepenuhnya berbeda. Kondisi ini terjadi dimungkinkan karena **mesin kasir di setiap cabang membuat nomor faktur secara mandiri tanpa sistem terpusat**, sehingga nomor yang sama tidak sengaja terpakai kembali di toko lain. Karena catatan tersebut merupakan **transaksi riil yang sah** dan bukan duplikasi data (double-entry), menghapusnya akan mengikis nilai pendapatan yang valid. Oleh karena itu, seluruh baris dipertahankan dan dibuatkan **Primary Key baru (Transaction_ID)** berbasis indeks unik untuk menjaga integritas basis data.

Data Exploration

Temuan Distribusi Data



Hasil Pengamatan

Visualisasi distribusi metrik finansial (Revenue, Cost, dan Margin) menunjukkan **pola kemiringan right-skewed** yang kuat, di mana **mayoritas transaksi menumpuk pada nilai nominal yang rendah**. Dalam karakteristik ritel FMCG, fenomena ini mengindikasikan **pola transaksi harian yang didominasi oleh pembelian bernominal kecil (low-ticket size) dengan frekuensi tinggi**. Namun, penumpukan ekstrem pada **nominal margin yang sangat tipis** mengindikasikan tingginya **kerentanan profitabilitas terhadap beban operasional**. Perusahaan direkomendasikan untuk menerapkan strategi **penataan merchandising** dan **product bundling** untuk **mengoptimalkan nilai keranjang belanja** serta **memperlebar margin** pada setiap transaksi.

Data Exploration

Hasil Pengamatan Data Exploration

Dataset ini memuat **100.000 baris transaksi dan 21 kolom**, yang secara teknis membutuhkan penyesuaian tipe data—seperti konversi Invoice_Date ke datetime dan 7 variabel ke category demi **efisiensi memori RAM**. Dari sisi kelengkapan, terdeteksi **missing values** pada aspek demografi pelanggan, yaitu **Customer_Age sebesar 40,08% dan Customer_Gender sebesar 5,05%**. Selain kelengkapan data, ditemukan isu integritas berupa **62 Invoice_ID terulang (0,06%)** dengan rincian transaksi yang sepenuhnya berbeda, yang terjadi kemungkinan karena **bentrok penomoran faktur di mesin kasir POS** antar cabang akibat belum adanya sistem terpusat. Terakhir, distribusi metrik finansial (Revenue, Cost, Margin) memperlihatkan **pola kemiringan right-skewed**, yang membuktikan bahwa operasional harian didominasi oleh pembelian bernominal kecil dengan frekuensi tinggi, serta **penumpukan transaksi pada nilai margin yang sangat tipis**.

Data Cleaning

1. Membuat dataframe baru yang bersih

```
# Membuat salinan dataframe agar data asli aman
df_clean = df.copy()
```

2. Mengubah Tipe Data

```
# A. Konversi Kolom Tanggal ke Datetime
df_clean['Invoice_Date'] = pd.to_datetime(df_clean['Invoice_Date'])

# B. Konversi ID ke String/Object
df_clean['Invoice_ID'] = df_clean['Invoice_ID'].astype(str)

# C. Konversi Customer_Age ke Nullable Integer ('Int64')
df_clean['Customer_Age'] = df_clean['Customer_Age'].astype('Int64')

# D. Konversi Loyalty_Flag ke Boolean (True/False)
df_clean['Loyalty_Flag'] = df_clean['Loyalty_Flag'].astype(bool)

# E. Konversi Kolom Kategorikal ke Category
kolom_kategori = [
    'City', 'Store_Format', 'Category', 'Brand',
    'Channel', 'Payment_Mode', 'Customer_Gender'
]
for col in kolom_kategori:
    df_clean[col] = df_clean[col].astype('category')
```

3. Penangan Missing Value

```
# 1. Penanganan Customer_Age: Membuat kolom baru pengelompokan umur (Age_Group)
df_clean['Age_Group'] = pd.cut(
    df_clean['Customer_Age'].fillna(-1),
    bins=[-2, 17, 25, 35, 50, np.inf],
    labels=['Unknown', '18-25', '26-35', '36-50', '51+']
)
# 2. Penanganan Customer_Gender: Mengisi missing value dengan kategori 'O' (Others)
if 'O' not in df_clean['Customer_Gender'].cat.categories:
    df_clean['Customer_Gender'] = df_clean['Customer_Gender'].cat.add_categories(['O'])

df_clean['Customer_Gender'] = df_clean['Customer_Gender'].fillna('O')
# Cek hasil akhirnya
print(df_clean['Age_Group'].value_counts())
print(df_clean['Customer_Gender'].value_counts())
```

```
Age_Group
Unknown    40081
36-50      19173
51+        17966
26-35      12676
18-25      10104
Name: count, dtype: int64
Customer_Gender
M    44920
F    44905
O    10175
```

Hasil Pengamatan

Proses pembersihan awal berhasil melakukan **standarisasi tipe data** (konversi ke datetime, string, boolean, dan category) untuk **efisiensi memori RAM** serta persiapan analisis berbasis waktu. **Missing values** pada variabel demografi telah **ditangani** secara terstruktur melalui **pengelompokan usia** (Age_Group) dengan label **'Unknown'** (40.081 data) serta **imputasi kategori 'O' (Others)** pada **gender (10.175 data)**. Struktur data kini bersih dan terstandardisasi, siap untuk tahap penanganan duplikasi Invoice_ID dan pembuatan Primary Key.

Data Cleaning

4. Penanganan Nilai Unik

```
# memastikan indeks rapi dan berurutan dari 0 sebelum dieksekusi
df_clean = df_clean.reset_index(drop=True)

df_clean['Transaction_ID'] = 'TRX-' + (df_clean.index + 1).astype(str)

# Memindahkan kolom Transaction_ID ke posisi paling depan
kolom_order = ['Transaction_ID'] + [col for col in df_clean.columns if col != 'Transaction_ID']
df_clean = df_clean[kolom_order]

# Tampilkan dataframe
display(df_clean)
```

Transaction_ID	Invoice_ID	Invoice_Date	City	Store_Format	Category	Brand	Channel
TRX-7232	10626453	2024-05-08 17:34:00	Ahmedabad	Super	Dairy	Nestle	Omnichannel
TRX-44818	10626453	2024-05-24 08:36:00	Hyderabad	Super	Personal Care	Parle	Omnichannel

Hasil Pengamatan

Pembuatan Primary Key baru (Transaction_ID) berbasis indeks unik (TRX-1, TRX-2, dst.) berhasil dieksekusi dan diposisikan di awal dataframe. Langkah ini menyelesaikan isu ID Collision pada Invoice_ID, sehingga setiap transaksi dari cabang berbeda yang memiliki nomor faktur sama kini teridentifikasi secara unik dan valid tanpa mengurangi data transaksi riil. Dataset kini memiliki integritas penuh untuk analisis tingkat transaksi (transaction-level analysis).

Data Cleaning

5. Feature Engineering

```
df_clean['Margin_Leakage_Flag'] = np.where(
    df_clean['Margin_%'] < 0.1933,
    'Underperforming',
    'Overperforming'
)
df_clean['Margin_Leakage_Flag'] = df_clean['Margin_Leakage_Flag'].astype('category')
display(df_clean[['Margin', 'Revenue', 'Cost', 'Margin_%', 'Margin_Leakage_Flag',]].head(10))
```

	Margin	Revenue	Cost	Margin_%	Margin_Leakage_Flag
0	52.116348	350.114418	297.998070	0.148855	Underperforming
1	25.407438	106.034197	80.626759	0.239616	Overperforming
2	138.734266	1044.900114	906.165848	0.132773	Underperforming

6. Feature Engineering pada Power BI

```
Customer Type = IF('finpro_cleaned'[Loyalty_Flag] = TRUE(), "Member", "Non-Member")
```

Hasil Pengamatan

Pembuatan Primary Key baru (Transaction_ID) berbasis indeks unik (TRX-1, TRX-2, dst.) berhasil dieksekusi dan diposisikan di awal dataframe. Langkah ini menyelesaikan isu ID Collision pada Invoice_ID, sehingga setiap transaksi dari cabang berbeda yang memiliki nomor faktur sama kini teridentifikasi secara unik dan valid tanpa mengurangi data transaksi riil. Dataset kini memiliki integritas penuh untuk analisis tingkat transaksi (transaction-level analysis).

Data Cleaning

7. Cek Outlier Numerikal

Kolom	Q1	Q3	IQR	Jumlah Outlier	Persentase (%)
Margin	24.45	110.08	85.63	4946	4.95
Revenue	155.42	573.06	417.65	1191	1.19
Cost	125.47	462.38	336.91	717	0.72
Selling_Price	71.33	188.85	117.53	0	0.00
Cost_Price	57.48	152.32	94.84	0	0.00
Units	2.00	4.00	2.00	0	0.00
Margin_%	0.13	0.26	0.13	0	0.00
Stock_On_Hand	161.00	387.00	226.00	0	0.00
Reorder_Level	34.00	64.00	30.00	0	0.00
Lead_Time_Days	6.00	12.00	6.00	0	0.00
Customer_Age	29.00	53.00	24.00	0	0.00

Hasil Pengamatan

Pemeriksaan outlier dengan metode IQR mendeteksi adanya pencilan pada metrik finansial, yaitu Margin (4,95%), Revenue (1,19%), dan Cost (0,72%), sedangkan seluruh variabel numerik lainnya bebas outlier (0%). Seluruh pencilan ini diidentifikasi sebagai pencilan alami bisnis (natural business outliers) yang dipicu oleh kombinasi kuantitas pembelian (units) serta nilai transaksi tinggi, bukan akibat kesalahan input data (data entry error). Oleh karena itu, data pencilan dipertahankan sepenuhnya tanpa pemotongan (trimming) maupun imputasi guna menjaga variabilitas transaksi riil dan mencegah distorsi pada kalkulasi total pendapatan.

Data Cleaning

8. Cek Outlier Kategorikal

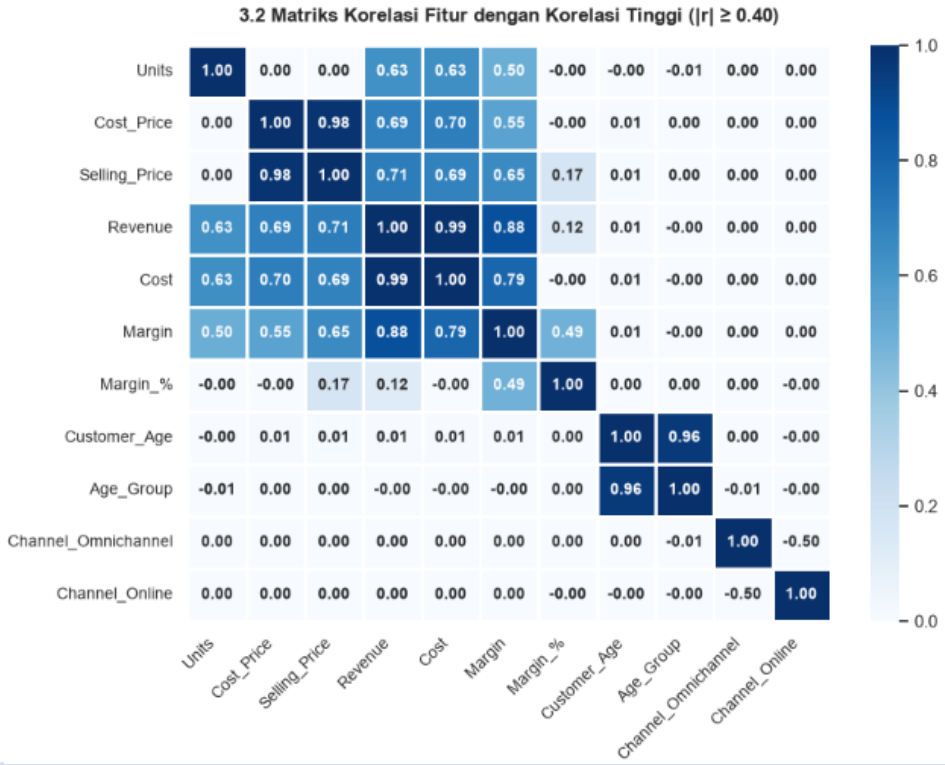
	Nama Kolom	Nilai Kategori	Frekuensi	Proporsi (%)	Status
0	Age_Group	18-25	10104	10.10	Normal
1	Age_Group	26-35	12676	12.68	Normal
2	Age_Group	51+	17966	17.97	Normal
3	Age_Group	36-50	19173	19.17	Normal
4	Age_Group	Unknown	40081	40.08	Normal
5	Brand	Parle	12233	12.23	Normal
6	Brand	Tata	12461	12.46	Normal
7	Brand	Britannia	12497	12.50	Normal
8	Brand	PepsiCo	12507	12.51	Normal
9	Brand	Amul	12521	12.52	Normal
10	Brand	Nestle	12560	12.56	Normal
11	Brand	HUL	12572	12.57	Normal
12	Brand	ITC	12649	12.65	Normal
13	Category	Dairy	12270	12.27	Normal
14	Category	Grocery	12412	12.41	Normal
15	Category	Personal Care	12409	12.41	Normal
16	Category	Vegetables	12472	12.47	Normal
17	Category	Snacks	12514	12.51	Normal
18	Category	Beverages	12585	12.58	Normal
19	Category	Home Care	12630	12.63	Normal
20	Category	Fruits	12708	12.71	Normal
21	Channel	Online	33255	33.26	Normal
22	Channel	Offline	33362	33.36	Normal
23	Channel	Omnichannel	33383	33.38	Normal
24	City	Pune	12403	12.40	Normal
25	City	Bengaluru	12432	12.43	Normal
26	City	Hyderabad	12440	12.44	Normal
27	City	Ahmedabad	12436	12.44	Normal
28	City	Chennai	12467	12.47	Normal
29	City	Mumbai	12492	12.49	Normal
30	City	Delhi	12649	12.65	Normal

Hasil Pengamatan

Seluruh variabel kategorikal berstatus Normal dengan distribusi seimbang (seperti Channel ~33% dan Brand/Category ~12–12,7%). Label 'Unknown' (40,08%) pada Age_Group menampung data tanpa usia secara konsisten. Tanpa adanya kategori langka, tidak diperlukan penggabungan kategori (grouping) sehingga seluruh variabel valid dan siap untuk analisis segmentasi.

Exploratory Data Analysis

Analisis Multivariat– Matriks Korelasi



Hasil Pengamatan

Evaluasi matriks korelasi menunjukkan bahwa kinerja finansial nominal (Revenue dan Margin) digerakkan secara kuat oleh tingginya harga jual (Selling_Price) dan kuantitas barang per transaksi (Units), bukan oleh besaran persentase keuntungan (Margin_%). Di sisi lain, ditemukan redundansi data (multikolinearitas ekstrem) pada profil usia pelanggan (Customer_Age dan Age_Group) dengan korelasi 0,96, serta pada Revenue dan Cost sebesar 0,99. Oleh karena itu, strategi penjualan disarankan berfokus pada taktik up-selling dan peningkatan ukuran keranjang belanja (basket size) alih-alih hanya mengejar margin persentase tinggi. Selanjutnya, untuk persiapan pemodelan machine learning, tim data disarankan melakukan seleksi fitur dengan menghapus variabel Customer_Age dan Cost guna menghindari bias akibat multikolinearitas.

Exploratory Data Analysis

Ekspor data yang sudah bersih

```
# 3. Export dataset bersih ke CSV (tanpa menyertakan index)
df_clean.to_csv('finpro_cleaned.csv', index=False)
print("Berhasil! Data siap diload ke Power BI.")
```

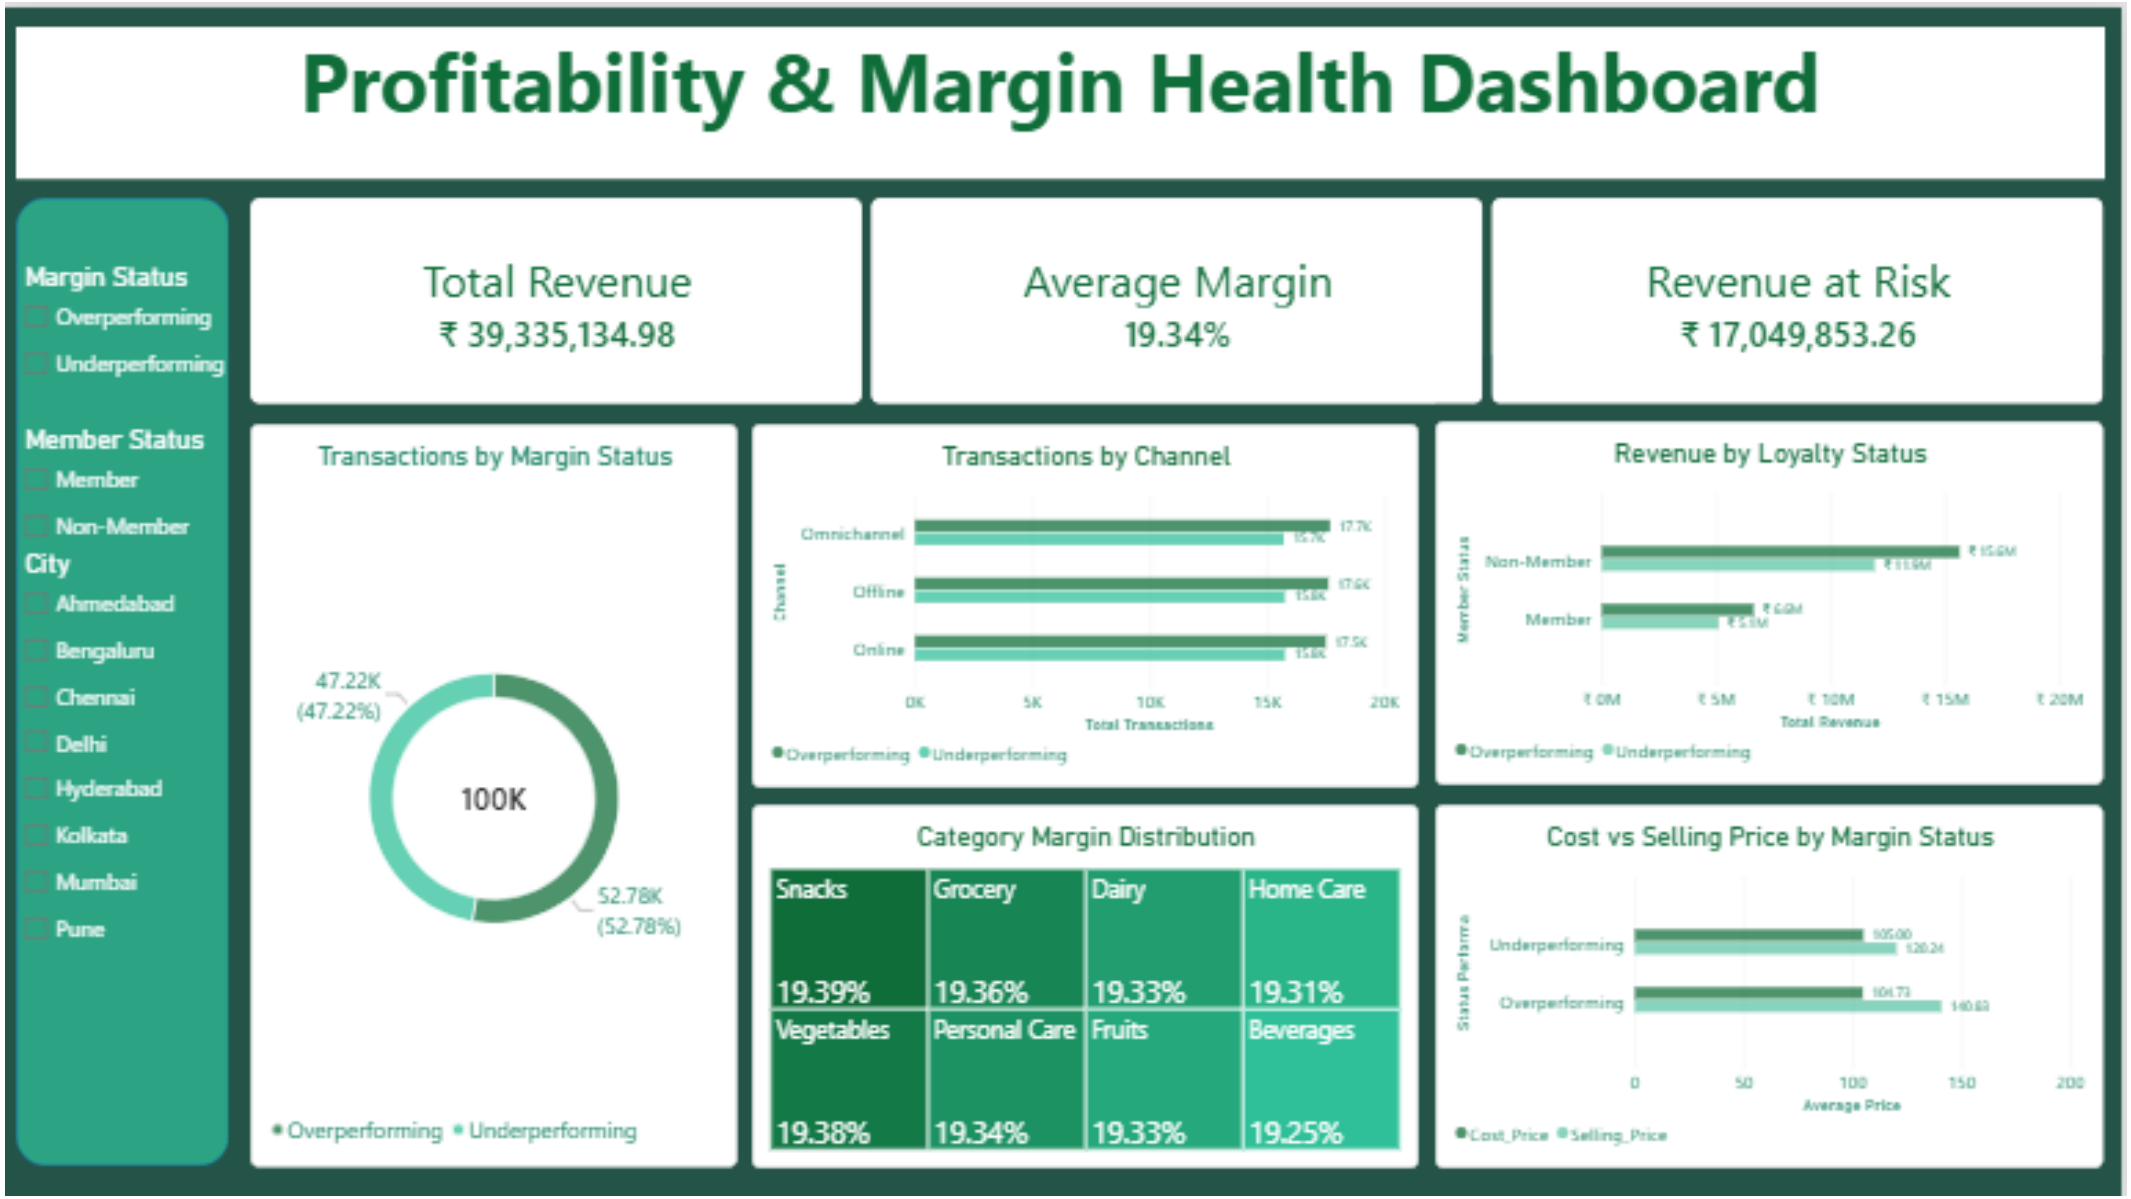
```
Berhasil! Data siap diload ke Power BI.
```

Link Github untuk dataset bersih: klik disini

Hasil Pengamatan

Dataset Sudah berhasil diekspor dan siap untuk dianalisis di aplikasi Power BI

Dashboard


Profitability & Margin Health Dashboard
Margin Status
Overperforming
Underperforming
Member Status
Member
Non-Member
City
Ahmedabad
Bengaluru
Chennai
Delhi
Hyderabad
Kolkata
Mumbai
Pune
Total Revenue
₹ 39,335,134.98
Average Margin
19.34%
Revenue at Risk
₹ 17,049,853.26
Transactions by Margin Status
47.22K
(47.22%)
100K
52.78K
(52.78%)
Overperforming
Underperforming
Transactions by Channel
Omnichannel
Offline
Online
Channel
0K
5K
10K
15K
20K
Total Transactions
Overperforming
Underperforming
Revenue by Loyalty Status
Non-Member
Member
Member Status
₹ 0M
₹ 5M
₹ 10M
₹ 15M
₹ 20M
Total Revenue
Overperforming
Underperforming
Category Margin Distribution
Snacks
19.39%
Grocery
19.36%
Dairy
19.33%
Home Care
19.31%
Vegetables
19.38%
Personal Care
19.34%
Fruits
19.33%
Beverages
19.25%
Cost vs Selling Price by Margin Status
Underperforming
Overperforming
Status Performa
0
50
100
150
200
Average Price
Cost_Price
Selling_Price

Data Analysis

1. Kondisi Bisnis Saat Ini - Ringkasan KPI Utama

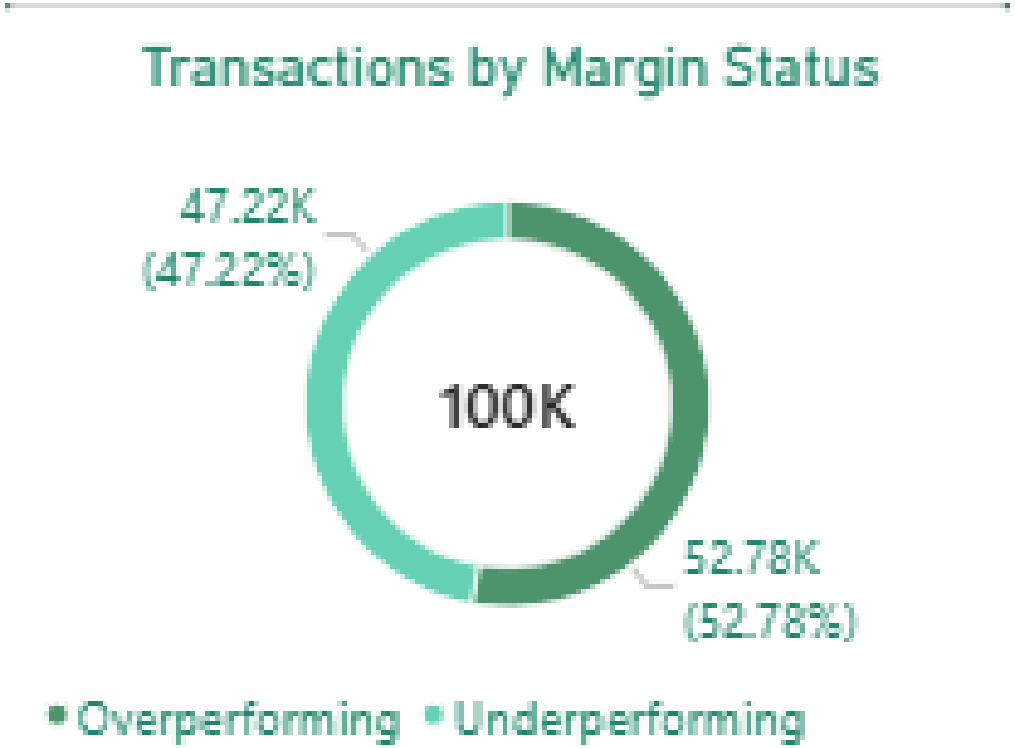
Total Revenue	Average Margin	Revenue at Risk
₹ 39,335,134.98	19.34%	₹ 17,049,853.26

Hasil Pengamatan

Perusahaan mencatatkan total pendapatan sebesar ₹39.335.134,98 dengan rata-rata margin 19,34%, namun menghadapi potensi risiko pendapatan (Revenue at Risk) mencapai ₹17.049.853,26 akibat tekanan pemberian diskon. Untuk menekan risiko tersebut dan mengamankan profitabilitas secara keseluruhan, perusahaan direkomendasikan melakukan evaluasi menyeluruh terhadap struktur diskon program loyalitas serta mengarahkan fokus penjualan pada lini produk dan kanal yang memiliki tingkat margin lebih sehat.

Data Analysis

2. Distribusi Status Performa Margin Transaksi

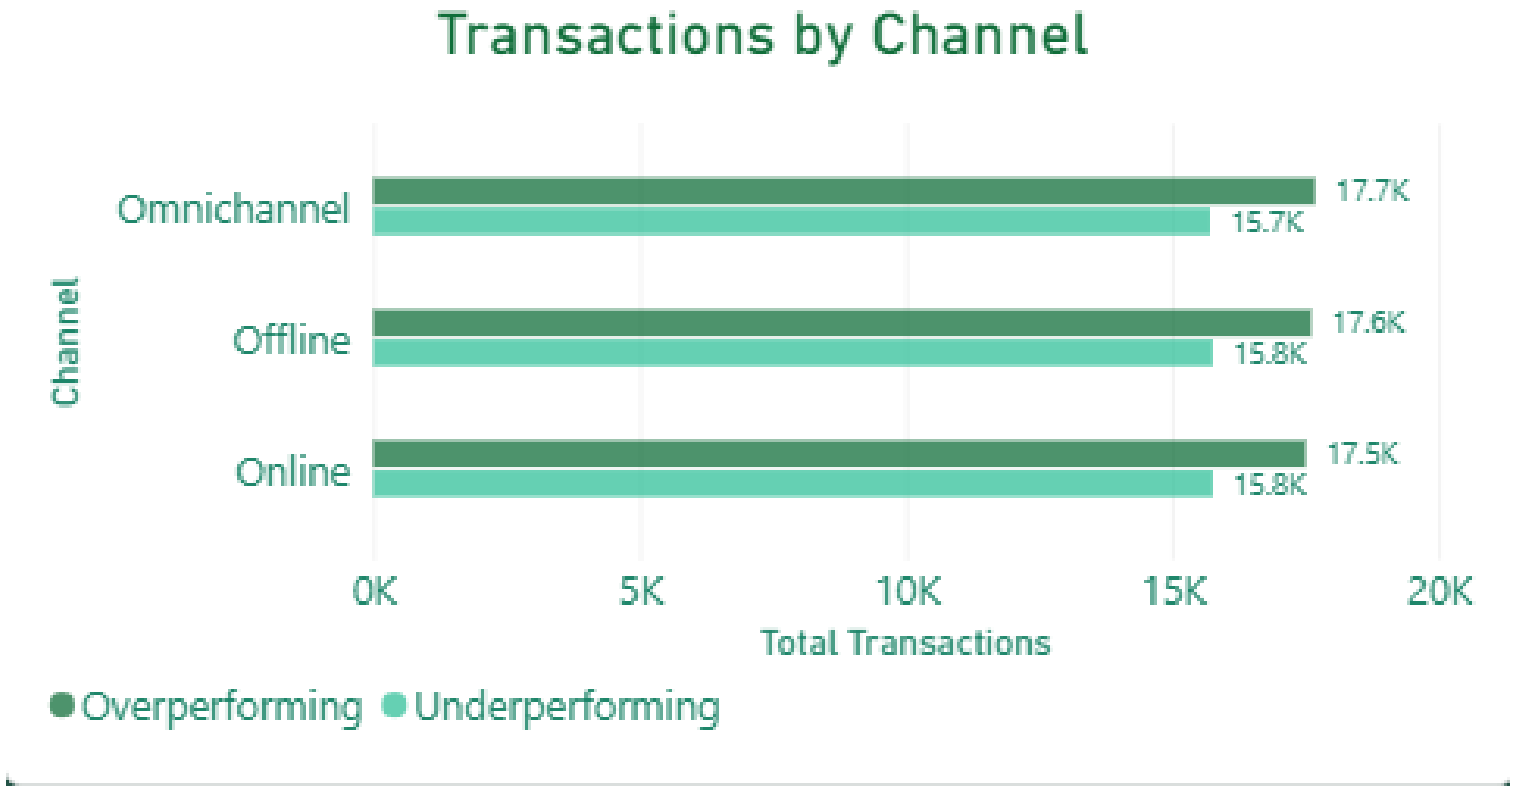


Hasil Pengamatan

Visualisasi menunjukkan bahwa dari 100.000 total transaksi, sebanyak 52,78% (52,78 ribu transaksi) berstatus Overperforming, sementara 47,22% (47,22 ribu transaksi) berada di kategori Underperforming. Perusahaan direkomendasikan untuk melakukan evaluasi ketat terhadap struktur harga dan diskon pada kelompok transaksi Underperforming guna menekan kebocoran margin, sekaligus mereplikasi strategi produk dari kelompok Overperforming untuk memperbesar proporsi transaksi yang menguntungkan.

Data Analysis

3. Performa Margin Berdasarkan Kanal Penjualan

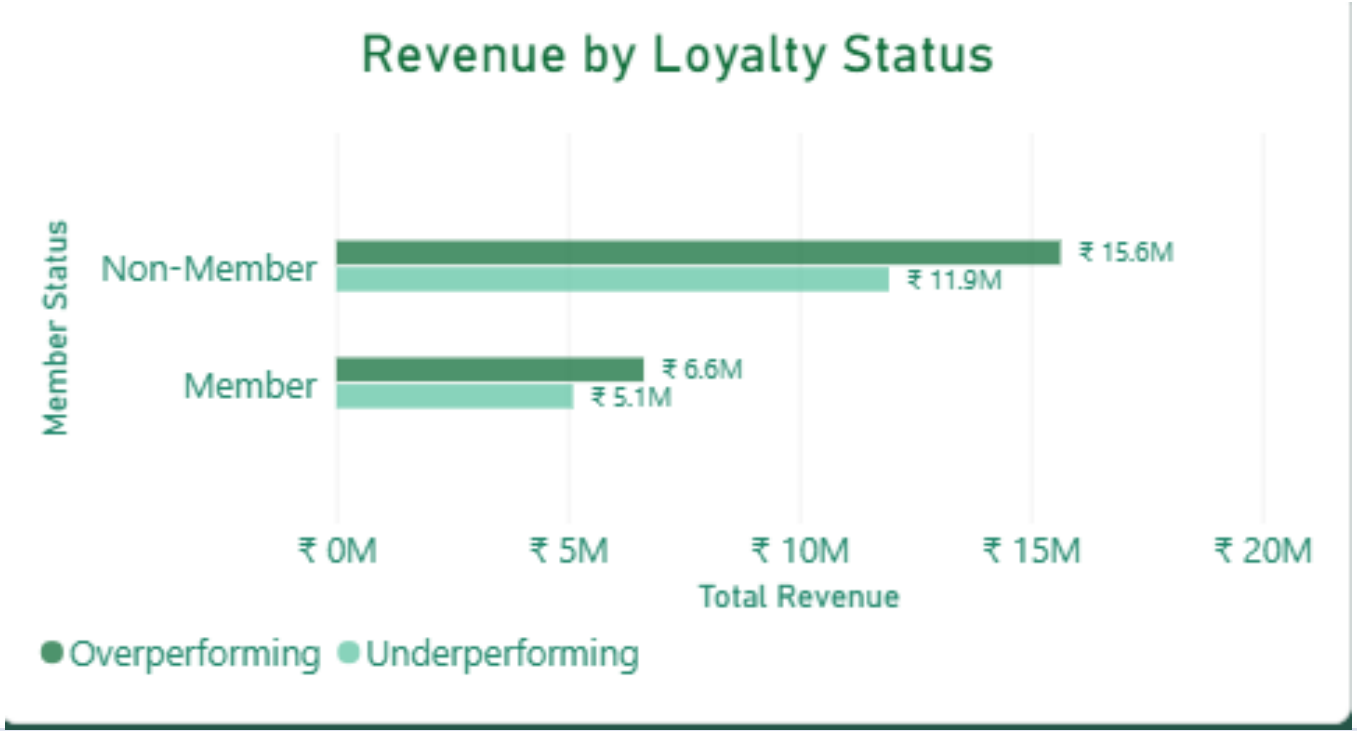


Hasil Pengamatan

Distribusi transaksi di seluruh kanal penjualan (Omnichannel, Offline, dan Online) menunjukkan sebaran yang merata pada kisaran 33,3K–33,4K transaksi, dengan proporsi transaksi Overperforming (17,5K–17,7K) secara konsisten mendominasi dibandingkan transaksi Underperforming (15,7K–15,8K). Kanal Omnichannel mencatatkan performa terbaik dengan jumlah transaksi menguntungkan tertinggi sebesar 17,7K transaksi. Berdasarkan temuan ini, perusahaan direkomendasikan untuk menerapkan pengetatan kebijakan diskon secara serentak di seluruh kanal guna mengurangi volume transaksi Underperforming, serta memprioritaskan alokasi strategi pemasaran pada kanal Omnichannel untuk mengoptimalkan potensi margin.

Data Analysis

4. Performa Margin Berdasarkan Kanal Penjualan

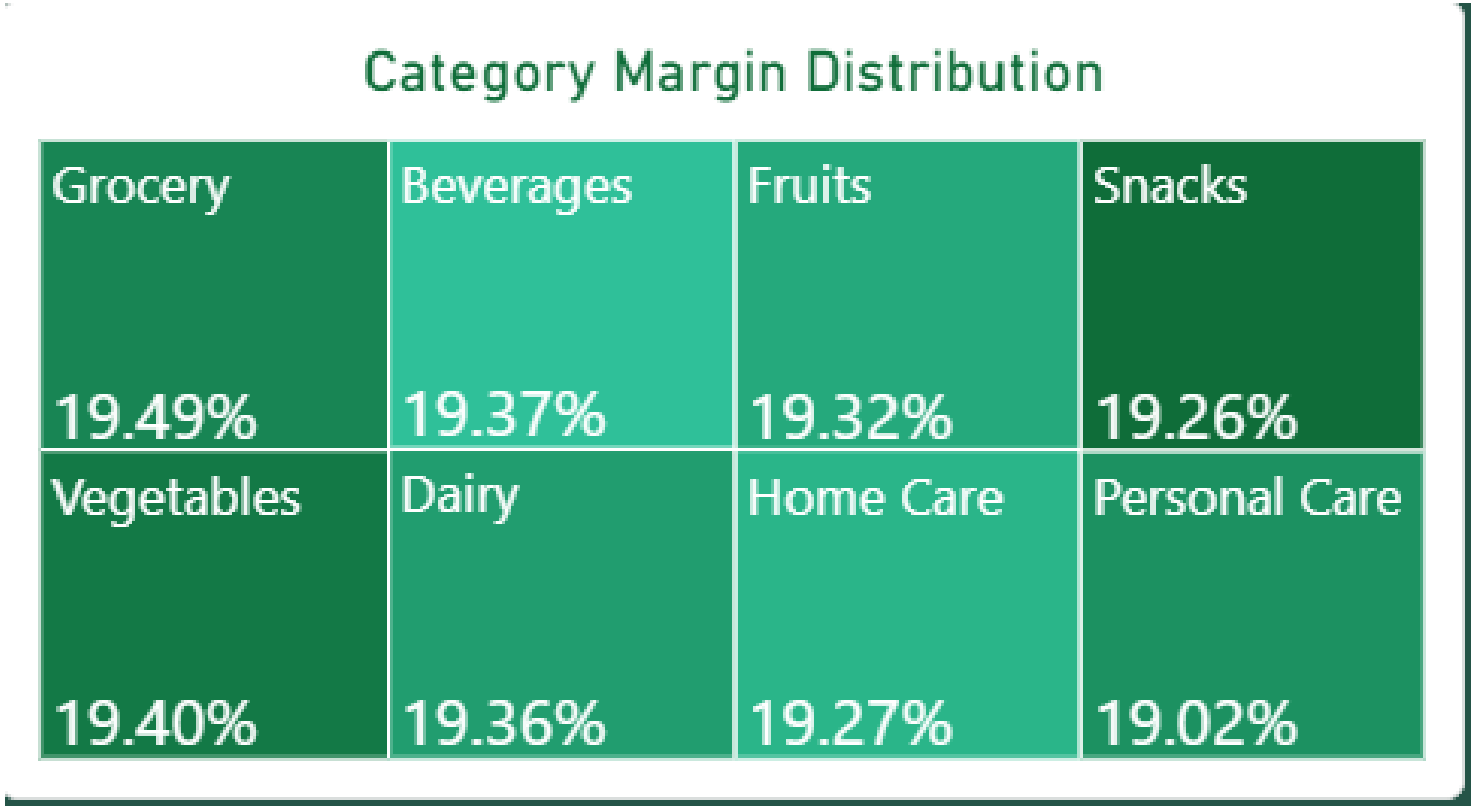


Hasil Pengamatan

Pelanggan kategori Non-Member menyumbang porsi pendapatan terbesar dengan rincian ₹15,6M pada status Overperforming dan ₹11,9M pada status Underperforming, jauh melampaui kontribusi kelompok Member (₹6,6M Overperforming dan ₹5,1M Underperforming). Meskipun penjualan Overperforming mendominasi di kedua kelompok, porsi pendapatan Underperforming masih tergolong signifikan yaitu mencapai sekitar 43% di masing-masing segmen. Perusahaan direkomendasikan untuk meninjau ulang skema insentif dan diskon program membership guna menekan kebocoran margin, serta merancang strategi konversi pelanggan Non-Member menjadi Member yang difokuskan pada produk-produk bertingkat margin tinggi.

Data Analysis

5. Distribusi Margin Rata-rata Berdasarkan Kategori Produk

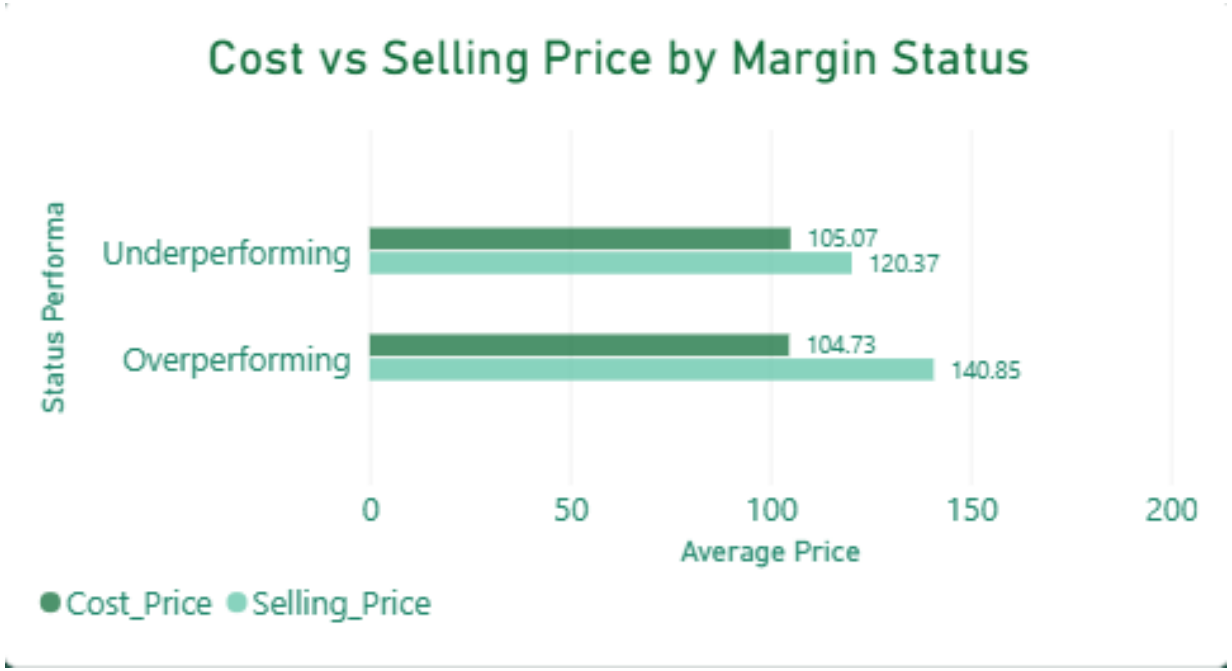


Hasil Pengamatan

Seluruh kategori produk mencatatkan rata-rata margin yang sangat ketat di kisaran 19,25% hingga 19,39%. Kategori Snacks (19,39%) dan Vegetables (19,38%) mencatatkan margin tertinggi, sedangkan Beverages (19,25%) berada di posisi terendah. Meskipun margin antar-kategori tergolong relatif seragam dan stabil, perusahaan direkomendasikan untuk meninjau ulang efisiensi harga dan promosi pada kategori Beverages guna mengerek margin mendekati kategori unggulan. Selain itu, manajemen perlu melakukan diversifikasi margin dengan mendorong penetapan harga diferensial (differential pricing) serta memprioritaskan alokasi bauran produk (product mix) pada varian produk bernilai tinggi di setiap kategori, sehingga rentang profitabilitas perusahaan lebih dinamis dan teroptimasi secara keseluruhan.

Data Analysis

6. Perbandingan Biaya Modal dan Harga Jual Berdasarkan Status Margin



Hasil Pengamatan

Rata-rata biaya modal (Cost Price) kedua kategori relatif setara (~104,7–105), namun harga jual (Selling Price) segmen Underperforming tertekan ke 120,37 dibanding Overperforming (140,85). Ini membuktikan bahwa kebocoran margin dipicu oleh pemberian diskon berlebihan, bukan tingginya HPP. Perusahaan direkomendasikan menetapkan batas bawah harga (price floor) dan memperketat batas maksimum diskon guna mengamankan target profitabilitas.

Hasil Analisa

Rata-rata keranjang belanja saat ini tertahan pada angka 2,98 barang per nota akibat tingginya proporsi pelanggan harian yang hanya membeli 1 hingga 2 item. Meskipun demikian, analisis aturan asosiasi menemukan korelasi pembelian terkuat pada kombinasi produk sausage, yogurt, dan whole milk dengan nilai Lift sebesar 2,18 yang mengindikasikan probabilitas tinggi produk-produk tersebut dibeli secara bersamaan. Sementara itu, pola aktivitas belanja harian mencatatkan puncak volume transaksi absolut tertinggi pada hari Kamis. Melalui simulasi data, potensi keberhasilan mengonversi 10% dari total transaksi saat ini diproyeksikan mampu meningkatkan rata-rata keranjang belanja (AOV) menjadi 3,28 barang per nota.

Rekomendasi

ntuk merespons temuan tersebut, manajemen disarankan mengoptimalkan tata letak toko dengan mendekatkan rak display sosis ke area chiller minuman serta menempatkan front-end chiller berisi aneka keju di jalur antrean kasir guna menangkap peluang impulse buying pada segmen keranjang kecil. Selanjutnya, tim pemasaran perlu memfokuskan alokasi anggaran diskon dan paket bundling untuk kombinasi sausage, yogurt, dan whole milk khusus pada hari Kamis guna memaksimalkan tingkat konversi saat trafik berada di puncaknya. Sebagai langkah eksekusi dengan risiko terukur, tim operasional disarankan menjalankan A/B Testing selama satu bulan penuh di area lorong Whole Milk dan Sausage guna memvalidasi efektivitas strategi ini dalam mencapai target AOV sebesar 3,28 barang.